Introduction à ILP
Analyse syntaxique

DLP : Développement d'un langage de programmation
Master STL, Sorbonne Université

Antoine Miné

Année 2020–2021

Cours 1
29 septembre 2019

Objectif du cours

Implantation d'un langage de programmation

Pratique et réflexion
autour de la **conception** et de l'**implantation** des langages :

- compilation et interprétation des programmes
- implantation des traits de haut-niveau des langages modernes
  pas un cours de génération d'assembleur ou d'allocation de registres !
- motivation des traits de langages, aspects historiques
  comparaison avec C, Java, ML, Smalltalk, etc.
- discussion des aspects sémantiques
- discussion des choix possibles d'implantation
- mise en pratique au sein du langage dédié au cours : ILP
- **lecture de code** ($\sim$ 30 Klignes de code fourni)
- extension du langage ILP
- programmation robuste et test

Langage cible : ILP

Langage de haut niveau, de type Javascript / Smalltalk.

- syntaxe à la ML (OCaml, etc.)
  la syntaxe est la partie la moins intéressante...
- valeurs entières, flottantes, chaînes et booléennes
- expressions avec opérateurs unaires et binaires (+, -, ==, <=, ...)
- structures de contrôle : alternatives, boucles, blocs
- variables globales et variables locales de bloc
- typage dynamique (pas de type statique associé à une variable)
- primitives (`print`, `newline`)
- fonctions globales et locales, fonctions de première classe (*lambdas*)
- exceptions
- objets, système de classes avec héritage
- gestion automatique de la mémoire (*garbarge collector*)

Technologie employée

Variété de Langages et outils : Java 8, C, ANTLR 4, Eclipse, JUnit 4.

- analyseur syntaxique : grammaire, en ANTLR 4
- **interprète en Java 8**
- **compilateur**, écrit en Java 8 et qui génère du code **C**
- bibliothèque d'exécution C pour le code généré
- test automatisé, avec JUnit 4
- développement au sein de la plateforme Eclipse
- sources distribuées sous Git

Cheminement

Versions de plus en plus élaborées du langage, de ILP1 à ILP4 :

- chaque version ajoute des fonctionnalités
- chaque version réutilise le code des versions précédentes

- **ILP1** : langage de base
  (pas de boucle, d'affectation, de fonction, d'exception, ni d'objet)
- **ILP2** : ajout des boucles, affectations, fonctions (globales)
- **ILP3** : ajout des exceptions, et fonctions locales et de première classe
- **ILP4** : ajout des classes et des objets

Règles :

- compatibilité ascendante : ILP4 peut exécuter un programme ILP1
- orthogonalité des extensions
- réutilisation maximale du code : pas (ou peu) de duplication
  (en Java : grâce à l'héritage et aux *design patterns*)

Ces règles sont suivies en cours, et sont à suivre en TME et en examen !

Organisation du cours

Deux chargés de cours : Carlos Agon & Antoine Miné.

- **cours 1–4 : ILP1** (langage de base)
  - cours 1 : introduction, analyse syntaxique, AST
  - cours 2 : interprète, visiteur
  - cours 3–4 : compilateur, bibliothèque d'exécution
- **cours 5 : ILP2**, boucles, affectations, fonctions
- **cours 6–7 : ILP3**
  - cours 6 : exceptions
  - cours 7 : fonctions de première classe
- **cours 8–9 : ILP4**
  - cours 8 : interprétation des objets
  - cours 9 : compilation des objets
- **cours 10 :** ramasse-miettes, révision

TME et évaluation

TME : une séance de 4h par semaine sur machine

- groupe 1 (jeudi) : Guillaume Hivert
- groupe 2 (jeudi) : Arthur Escriou
- groupe 3 (vendredi) : Gonzalo Romero

Principe : étendre ILP (syntaxe, interprète, compilateur, test)

Évaluation : deux épreuves, + TME

- 10 % : TME, travail hebdomadaire
- 40 % : partiel, sur les cours 1 à 5 (ILP1 à ILP2)
- 50 % : examen final, sur les cours 1 à 10 (ILP1 à ILP4)

Même principe que les TME ! (mais correction à la main)

Importance du travail personnel :

- **lire** en détail chez soi les sources d'ILP
- terminer chez soi les TME
- maintenir son espace de travail Eclipse à jour (dernière version d'ILP, TME)

Historique du cours

Inspiré librement du cours original de Christian Queinnec.

Ressources d'archive utiles :

1. cours ILP à l'UPMC de Christian Queinnec, édition 2007–2008
   transparents et bande son sur :
   `http://www-master.ufr-info-p6.jussieu.fr/2007/Ext/queinnec/ILP/`
2. cours *compiler reading* de Christian Queinnec à l'INSTA :
   `https://compiler-reading-1.appspot.com/course/`
3. annales 2015–2016 d'ILP sur le site du Master STL à l'UPMC :
   `https://www-master.ufr-info-p6.jussieu.fr/2015/DLP`

Attention cependant, modifications importantes !

Plan du cours

Cours 1 : du programme source à l'arbre syntaxique abstrait

- schéma général d'ILP
- langage ILP1 :
  - syntaxe
  - éléments (informels) de sémantique
- générateur d'analyseur syntaxique : ANTLR 4
- AST (arbre syntaxique abstrait)
- tests JUnit 4

Schéma général d'ILP

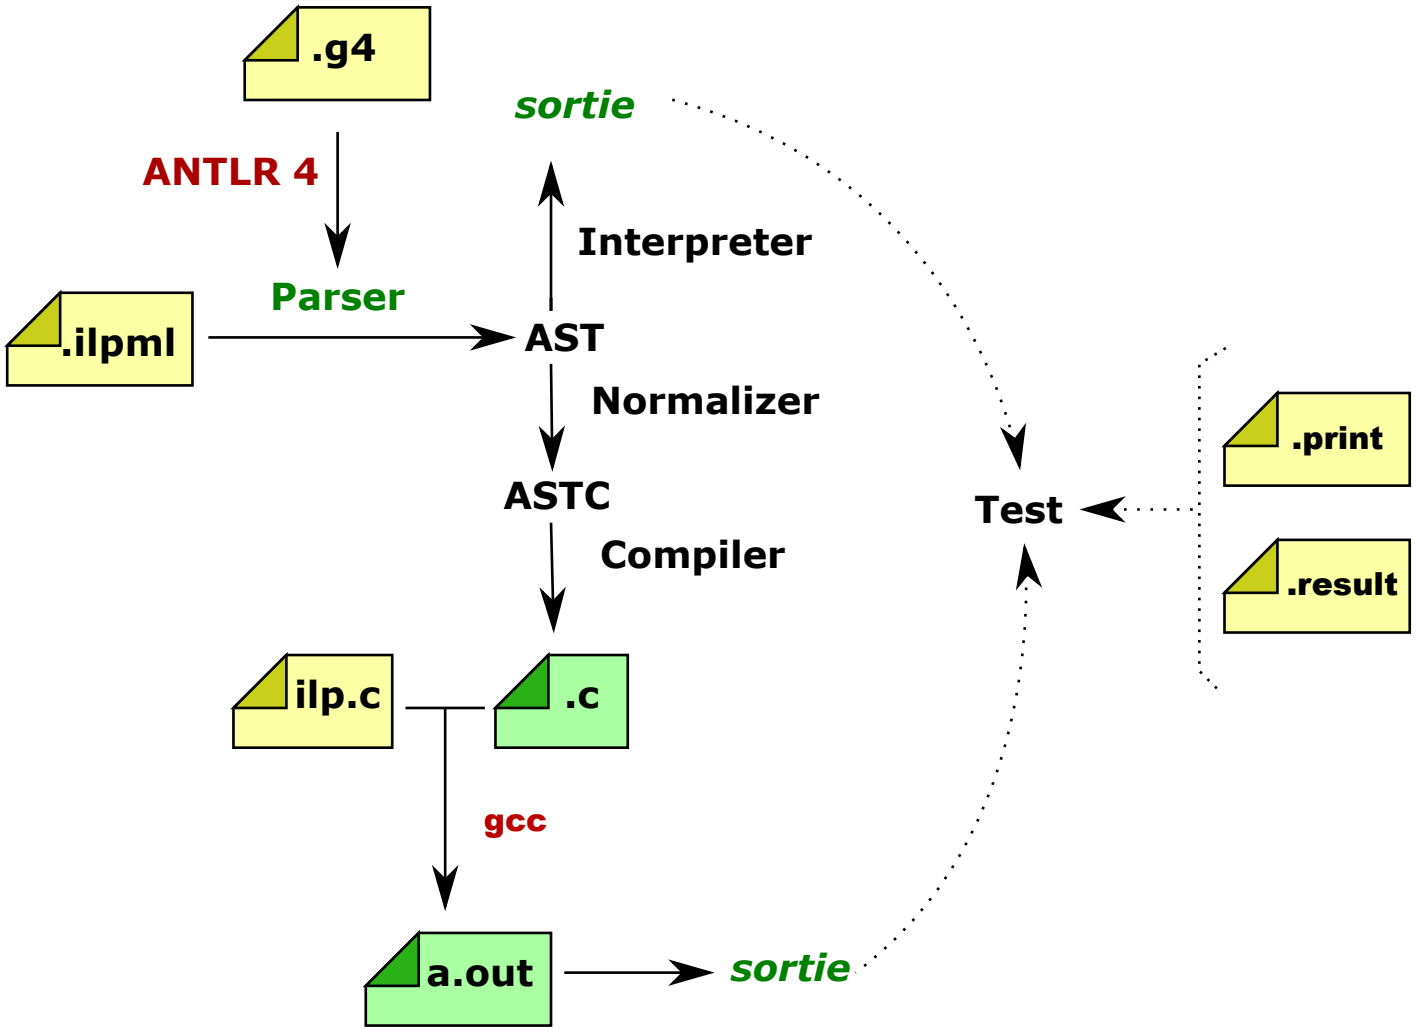

Architecture du code

Le projet Eclipse `ILP` contient de nombreux répertoires.

Aujourd'hui, nous regardons surtout :

- `Java/src/`
  - `com.paracamplus.ilp1.ast`
  - `com.paracamplus.ilp1.interfaces`
  - `com.paracamplus.ilp1.parser`
  - `com.paracamplus.ilp1.parser.ilpml`
  - `com.paracamplus.ilp1.test`
  - `com.paracamplus.ilp1.interpreter.test`
  - `com.paracamplus.ilp1.compiler.test`
- `ANTLRGrammars/` (fichiers de grammaire ANTLR pour une syntaxe ML)
- `target/generated-sources/` (fichiers générés par ANTLR)
- `SamplesILP1/` (exemples de source ILP1)

Analyse syntaxique

But

L'analyse syntaxique transforme une séquence de caractères,
i.e., le programme source,
en une représentation arborescente décrivant la structure du programme
et précisant la nature de chaque mot ou symbole (l'AST).

source

```
let x = 1 in
 let y = 12 in
  if y == 25 then print(x)
```

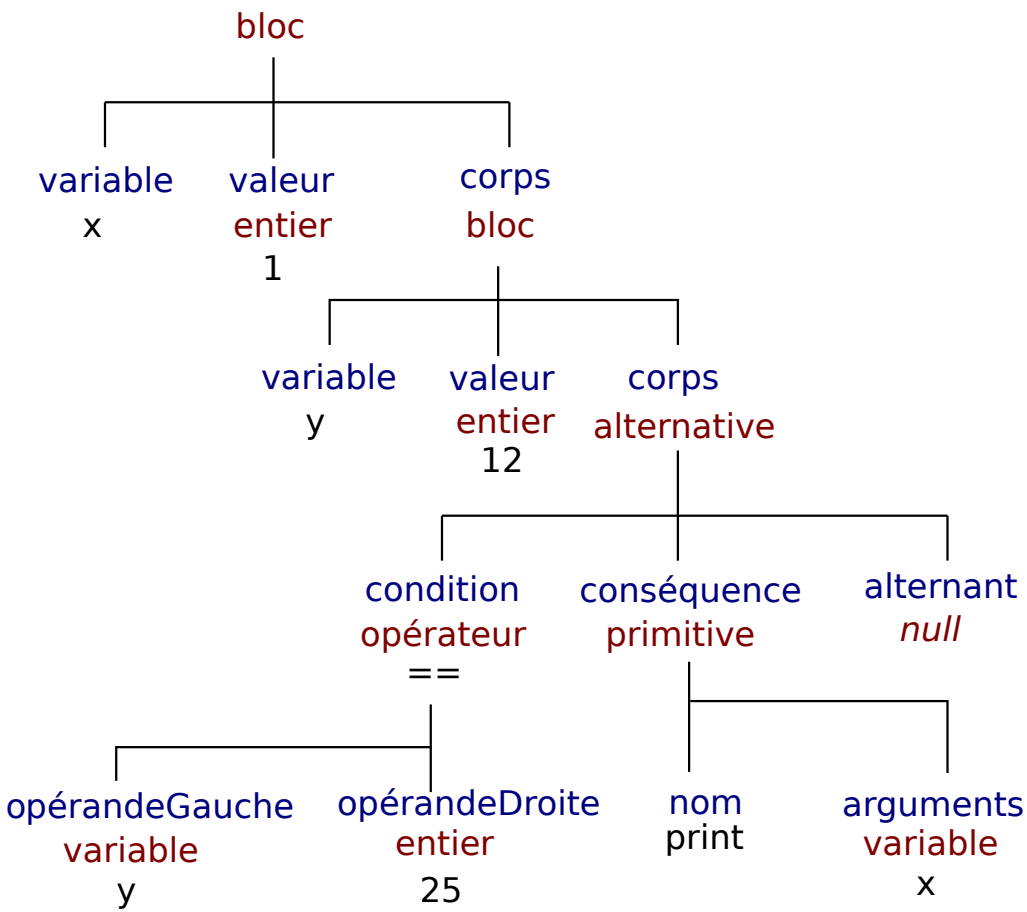

Outil : les expressions régulières

Des séquences de lettres aux "mots" (*tokens*).

Une expression régulière représente un ensemble de mots avec :

- des caractères : `a`, `b`, ...
- l'opérateur de concaténation (invisible)
- l'opérateur de choix : `|`
- les opérateurs de répétition : `+` (une fois au moins), `*` (zéro, une fois, ou plus)
- l'opérateur d'option : `?`
- des parenthèses : `(`, `)`

$\Longrightarrow$ utile pour décrire les entiers, flottants, chaînes, noms de variable, etc. de notre langage.

cf. `grep`, `Perl`

Outil : les grammaires

Des séquences de mots aux "phrases".

Grammaire hors contexte : ensemble de règles de la forme

`<non-terminal1>` := *expression* | ... | *expression*
`<non-terminal2>` := *expression* | ... | *expression*
...

où une expression contient :

- des non terminaux `<non-terminal>` (i.e., des variables)
- des terminaux "`a`", "`let`",... (i.e., des caractères, des mots)
- des parenthèses

$\Longrightarrow$ c'est la notation BNF (Backus Naur Form)

- par extension, les opérateurs `+`, `*`, `?`, `|` des expressions régulières
  (utiles seulement pour la lisibilité : ils peuvent être exprimés dans BNF)

Règles récursives : une phrase est composée de sous-phrases.

Plus expressif que les expressions régulières
$\Longrightarrow$ bien adapté aux langages structurés.

Syntaxe concrète du langage ILP1

Syntaxe ILPML (programmes ILP avec une syntaxe ML).

<programme> := (<expr> ";"?)* EOF

<expr> := <variable>

(constantes) | "true" | "false" | <entier> | <flottant> | "\"<chaîne>\""

(opérations unaires) | ("-" | "!") <expr>

(opérations binaires) | <expr> ("+" | "-" | ... | ">=" | "==") <expr>

(variables locales) | "let" <variable> "=" <expr> ("and" <variable> "=" <expr>)* "in" <expr>

(alternative) | "if" <expr> "then" <expr> ("else" <expr>)?

(séquence) | "(" <expr> (";"? <expr>)* ";"? ")"

(appel) | <variable> "(" <expr>? ("," <expr>)* ")"

<entier> := ("0" | ... | "9")+

<variable> := ("a" | ... | "Z" | "_") ("0" | ... | "9" | "a" | ... | "Z" | "_")*

⋮

Note : les points-virgules sont en fait optionnels dans notre langage, mais utiles pour la lisibilités !

Exemples de programmes ILP1

```
print("Un, ");
print("deux et ");
print("trois.")
```

```
let x = 1
and y = 2 in
x + y
```

```
print (2.5 - 1)
```

```
if false then print("invisible");
47
```

Voir également les fichiers `.ilpml` du répertoire `SamplesILP1`.

Éléments de sémantique : les expressions

Certains choix sémantiques sont déjà visibles au niveau de la syntaxe !

La plus part des langages distinguent :

- les instructions, qui ont un effet et ne renvoient pas de valeur
- les expressions, qui renvoient une valeur

e.g., C, Java, JavaScript, Python, etc.

D'autres, comme Lisp, ML ou ILP ne font pas cette distinction

$\Longrightarrow$ tout est expression et renvoie une valeur :

- `(expr1; expr2; ...; exprN)`
  renvoie la valeur de `exprN`
- `if expr1 then expr2 else expr3`
  renvoie la valeur de `expr2` ou `expr3` (selon la valeur de `expr1`)
- `let x = expr1 in expr2`
  renvoie la valeur de `expr2`

Éléments de sémantique : les expressions

En ILP, tout est expression et renvoie une valeur.

Avantages :

- uniformité, simplicité du langage.
- expressivité ; on peut écrire : `let x = if y then 1 else 2`

Inconvénient :

Certaines expressions n'ont pas de valeur naturelle :

- `if expr1 then expr2`, quand `expr1` est fausse
- `print(x)`
- ce sera aussi le cas pour les boucles `while` dans ILP2

$\Longrightarrow$ ILP choisit de renvoyer `whatever`

Éléments de sémantique : portée des variables

Portée :

Les variables sont déclarées locales avec `let`.

nous verrons des variables globales dans ILP2

- les variables n'existent que dans leur portée

  e.g., dans `let x = expr1 in expr2`,
  `x` n'existe que dans `expr2`.

- une variable peut en masquer une autre

  e.g. : `let x = 5 in (let x = 12 in x) + x`

Tous les langages modernes suivent ces convention !

(avec des variations sur la notion de bloc lexical, e.g. en Python. . .)

Éléments de sémantique : typage dynamique

Typage : de nombreux systèmes de types existent !

- typage statique avec déclaration (C, Java)
- typage statique avec inférence (ML)
- typage dynamique (JavaScript, Python, ILP)

En ILP, une variable n'est pas déclarée avec un type.

Elle prend le type de la valeur qui lui est affectée.

e.g., `let x = if ... then 12 else "Coucou" in print(x)`

Nous verrons en ILP2, avec l'affectation, que le type de la valeur affectée dans une variable peut varier au cours de l'exécution.

$\Longrightarrow$ les variables n'ont pas de type, seules les valeurs ont un type.

Éléments de sémantique : sûreté du typage

Erreur de type :
utilisation d'un opérateur avec une valeur d'un type non adapté.
(e.g., additionner des booléens)

Sûreté du typage :

- typage faible : comportement indéfini (e.g., C)
- typage fort : détection systématique et gestion "propre" des erreurs
  (e.g., Java, ML, ILP)

En ILP, toute valeur a un type bien défini.

Toutes les erreurs de type sont détectées à l'exécution.

e.g., `2 + "Coucou"` termine le programme avec un message d'erreur.

Éléments de sémantique : les opérateurs

- `+` : additionne deux nombres ou deux chaînes
- `-`, `*`, `/` : opération sur deux nombres
- `%` : modulo sur deux entiers
- `==`, `>=`, `<=`, `<`, `>`, `!=` : comparaison de deux nombres
- `&`, `|`, `^` : opération logique sur deux booléens
- `-` : opposé d'un nombre
- `!` : négation d'un booléen

"nombre" signifie ici un entier ou un flottant :

- si tous les arguments sont entiers, le résultat est entier
- si un argument au moins est flottant, le résultat est flottant

De plus, une valeur non-booléenne est considérée comme `true` pour un opérateur booléen.

cf. `com.paracamplus.ilp1.interpreter.operator`

Éléments de sémantique : les primitives

Primitive : variable ou fonction prédéfinie.

- `pi` : la constante 3.1415926535
- `print(expr)` : affiche la valeur de l'expression `expr` (quel que soit son type)
- `newline()` : affiche un saut de ligne

Considéré comme une variable / fonction par l'analyseur syntaxique, reconnu spécialement par l'interprète et le compilateur.

Avantages :

- évite d'encombrer la grammaire
- très facile d'ajouter de nouvelles primitives

cf. `com.paracamplus.ilp1.interpreter.primitive`

ANTLR 4

ANTLR : générateur d'analyseurs syntaxiques.

(cf., `lex` et `yacc` / `bison`, etc.)

- part d'une grammaire au format `.g4`
  proche de la syntaxe BNF
- génère un "reconnaisseur" pour le langage de la grammaire, en Java

  paramétré par une classe visiteur ou *Listener* fournie par l'utilisateur

Sources fournies et sources générées

- grammaire fournie : `ANTLRGrammars/ILPMLgrammar1.g4`
- ANTLR 4 génère les sources Java
  - `ILPMLgrammar1Lexer.java` : analyse lexicale (lettres en mots)
  - `ILPMLgrammar1Parser.java` : analyse syntaxique (mots en phrases)
  - `ILPMLgrammar1Listener.java` : interface de *Listener* à implanter
  - `ILPMLgrammar1BaseListener.java` : implantation vide du *Listener* à sous-classer

  les sources sont dans `target/generated-sources` et dans le package `antlr4`
- nous fournissons également le source Java :
  - `ILPMLListener.java` dans `com.paracamplus.ilp1.parser.ilpml` implantation du *Listener*, i.e., de `ILPMLgrammar1Listener`

Grammaire ANTLR pour ILP1

ANTLRGrammars/ILPMLgrammar1.g4 (extrait)

```
grammar ILPMLgrammar1;
@header { package antlr4; }

// Règles syntaxiques
prog returns [com.paracamplus.ilp1.interfaces.IASTprogram node]
    : (exprs+=expr ';'?) * EOF
    ;
expr returns [com.paracamplus.ilp1.interfaces.IASTexpression node]
    : '(' exprs+=expr (';'? exprs+=expr)* ';'? ')' # Sequence
    | fun=expr '(' args+=expr? (',' args+=expr)* ')' # Invocation
    | op=('-' | '!') arg=expr # Unary
    | arg1=expr op=('*' | '/' | '%') arg2=expr # Binary
    | arg1=expr op=('+' | '-') arg2=expr # Binary
    | arg1=expr op=('<' | '<=' | '>' | '>=') arg2=expr # Binary
    | ...
    | 'let' vars+=IDENT '=' vals+=expr ('and' vars+=IDENT '=' vals+=expr)*
      'in' body=expr # Binding
    | 'if' condition=expr 'then' consequence=expr
      ('else' alternant=expr)? # Alternative
    ;

// Règles lexicales
IDENT : [a-zA-Z_] [a-zA-Z0-9_]*;
INT : [0-9]+;
...
SPACE : [ \t\r\n]+ -> skip;
```

Reconnaisseur ANTLR et *Listener*

schéma de règle ANTLR

```
non_terminal returns [type attr]
  : var1=expr1 ... varN=exprN # NomRègle1
  | var1=expr1 ... varM=exprM # NomRègle2 ;
```

Nous utilisons l'interface *Listener* d'ANTLR.

Principe :

- ANTLR parcours le texte du source caractère par caractère
- dès qu'une règle NomRègle est applicable, ANTLR appelle le *Listener*

  `enterNomRègle(NomRègleContext ctx)`
  `exitNomRègle(NomRègleContext ctx)`
- si une règle contient des non-terminaux
  leur `enter` / `exit` sont appelés entre `enterNomRègle` et `exitNomRègle`
- le contexte `ctx` a un champ `attr` de type `type`
- le contexte `ctx` a des champs `var1`, ..., `varN` (dépendant de la règle)
  donnant accès au contexte des sous-expressions
  ⇒ `ctx.attr` est calculé à partir de `ctx.var1.attr`, ..., `ctx.varN.attr`

Reconnaisseur ANTLR : exemple

exemple de grammaire

```
expr returns [Integer val]
  : e1=expr '+' e2=expr   # Add
  | '-' e=expr            # Neg
  | i=INT                 # Const ;
```

exemple de source

```
12 + -4
```

ANTLR appellera dans l'ordre :

```
enterAdd
  enterConst
  exitConst
  enterNeg
    enterConst
    exitConst
  exitNeg
exitAdd
```

ANTLR fournit les types :

`AddContext ctx` :
  `Integer ctx.val, ctx.e1.val, ctx.e2.val`

`NegContext ctx` :
  `Integer ctx.val, ctx.e.val`

`ConstContext ctx` :
  `Integer ctx.val`
  `Token ctx.i` (type des terminaux ANTLR)

Exemple : implantation d'une calculatrice simple

```
exitAdd(AddContext ctx) { ctx.val = ctx.e1.val + ctx.e2.val; }
exitNeg(NegContext ctx) { ctx.val = -ctx.e.val; }
exitConst(ConstContext ctx) { ctx.val = Integer.parseInt(ctx.i.getText()); }
```

Priorité des règles en ANTLR

La règle BNF : <expr> : := <expr> + <expr> | <expr> * </expr>
est ambiguë : 1+2*3 peut être vu comme 1+(2*3) ou (1+2)*3.

ANTLR résout ce problème à l'aide d'un système de priorités implicites.

exemple : opérations binaires

```
expr returns [com.paracamplus.ilp1.interfaces.IASTexpression node]
    ...
    | arg1=expr  op=('*' | '/' | '%')          arg2=expr  # Binary
    | arg1=expr  op=('+' | '-')                arg2=expr  # Binary
    | arg1=expr  op=('<' | '<=' | '>' | '>=')  arg2=expr  # Binary
    | arg1=expr  op=('==' | '!=')              arg2=expr  # Binary
    | arg1=expr  op='&'                        arg2=expr  # Binary
    | arg1=expr  op=('|' | '^')                arg2=expr  # Binary
```

- les lignes en premier ont une priorité plus élevée
  1+2*3 est vu comme 1+(2*3)
- tous les opérateurs d'une ligne ont la même priorité
  avec associative à gauche par défaut
  1+2-3 est vu comme (1+2)-3

autre exemple : "`if true then 1 + 2`" est vu comme "`if true then (1+2)`"

Arbre syntaxique abstrait

Arbre syntaxique abstrait

Principe : représentation du programme

- abstraite, oubliant les détails non importants
  (espaces, parenthèses, sucre syntaxique)
- non-ambiguë (priorité des opérateurs résolue)
- structuré (arbre)
- facile à manipuler

Dans ILP, nous utilisons des bonnes pratiques de programmation objet :

- programmation vis à vis d'une interface
- héritage pour factoriser le code
- utilisation de *design patterns* : fabrique, visiteur.

L'extension de ILP1 à ILP4, et les TME, nous donneront l'occasion d'apprécier les bénéfices de ces bonnes pratiques !

Hiérarchie d'interfaces IAST

Les interfaces de l'AST ont pour préfixe `IAST`
et dérivent de l'interface `IAST`.

Package `com.paracamplus.ilp1.interfaces` :

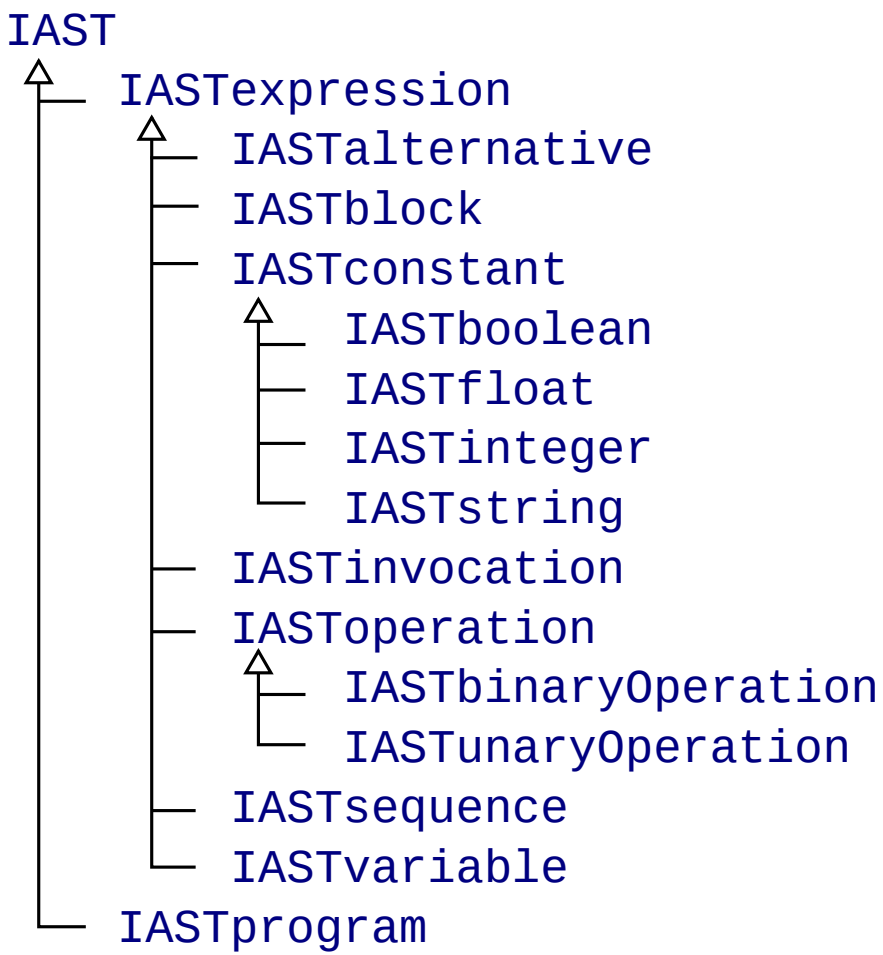

Interfaces d'AST : IAST, IASTexpression

IAST.java

```
package com.paracamplus.ilp1.interfaces;
public interface IAST {
  /* vide ! */
}
```

Interface marqueur (sans méthode)
servant de racine à la hiérarchie d'IAST.

IASTexpression.java

```
package com.paracamplus.ilp1.interfaces;
public interface IASTexpression extends IAST, IASTvisitable {
  /* vide ! */
}
```

`IASTexpression` distingue les expressions des programmes complets.

ILP2 introduira des déclarations de fonctions dans les programmes ; ce ne sont pas des expressions.

`IASTvisitable` sert à implanter le *design pattern* visiteur, cf. prochain cours.

Interfaces d'AST : `IASTalternative`

IASTalternative.java

```
public interface IASTalternative extends IASTexpression {
    IASTexpression getCondition();
    IASTexpression getConsequence();
    @OrNull IASTexpression getAlternant();
    boolean isTernary();
}
```

Modélise : `if` *`condition`* `then` *`consequence`* `else` *`alternant`*.

`@OrNull` est une annotation Java
indiquant que `getAlternant` peut retourner `NULL`.

en l'absence d'annotation `@OrNull`, nous pouvons supposer que la méthode ne renvoie jamais `null` ;
cette annotation, spécifique à ILP, n'est là qu'à titre informatif ;
elle n'est pas exploitée ni vérifiée par Java...
cf. `com.paracamplus.ilp1.annotation.OrNull`

Hiérarchie de classes d'AST

Package `com.paracamplus.ilp1.ast` :

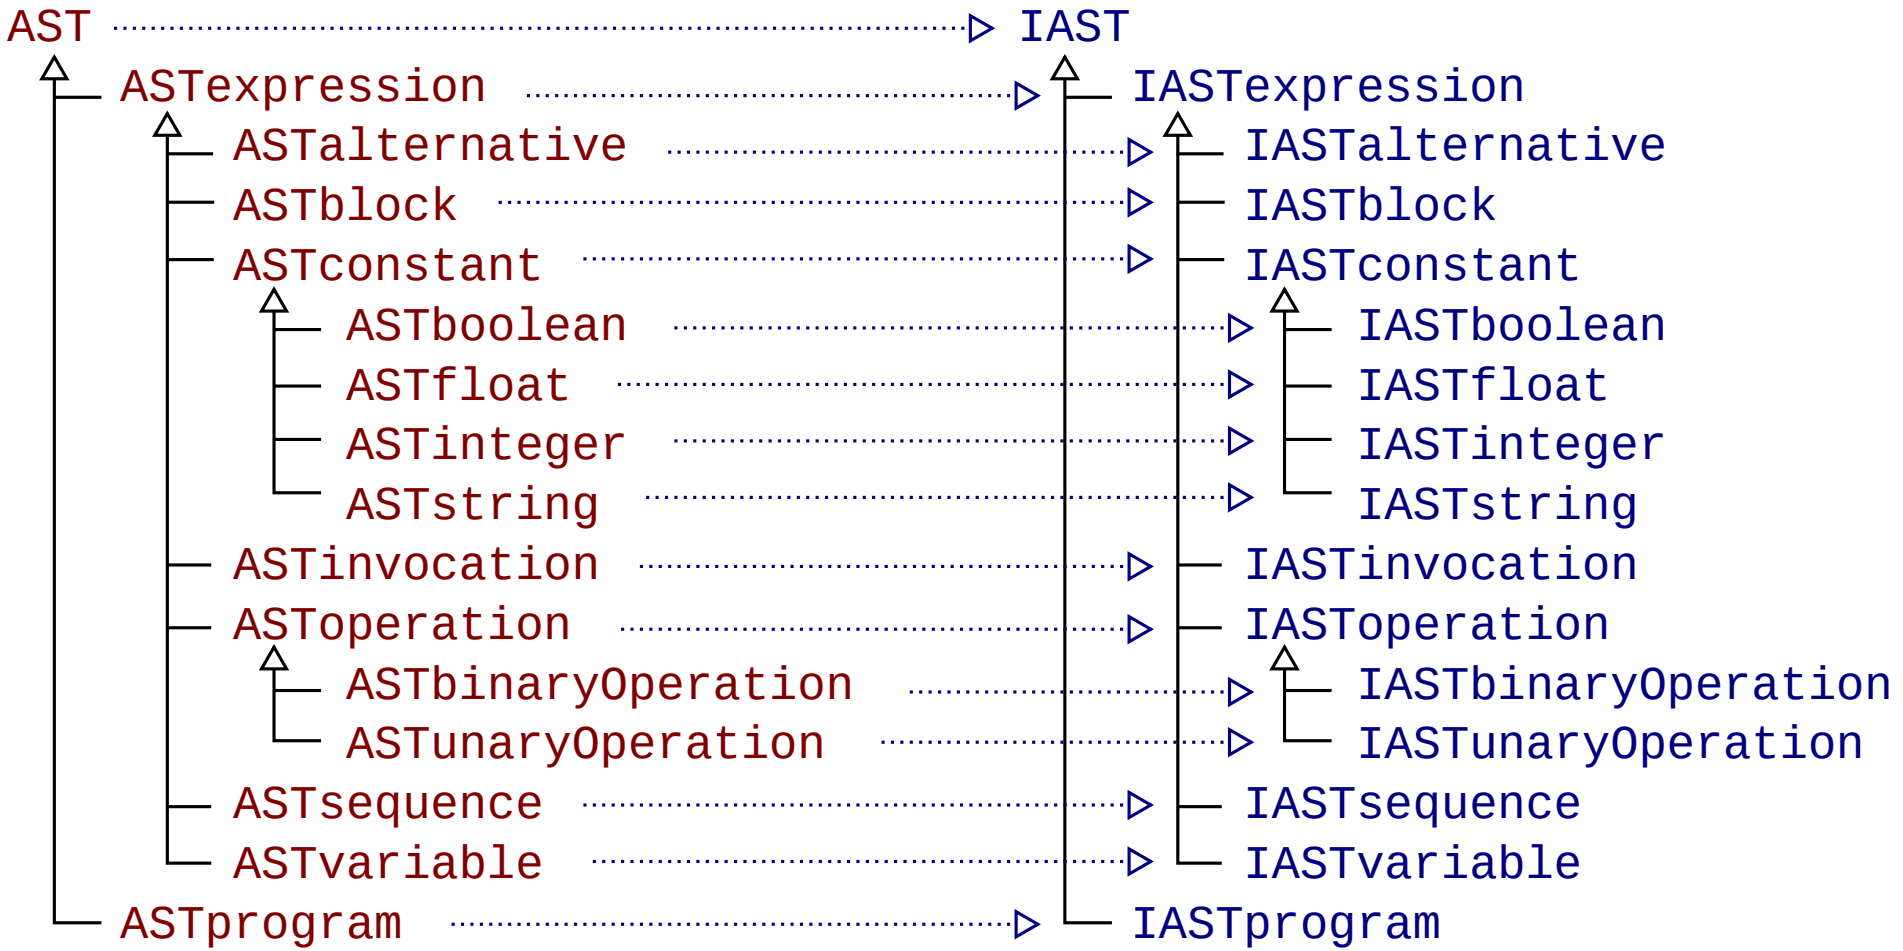

Chaque classe `AST` implante une interterface `IAST` correspondante,
et a les mêmes relation d'héritage que l'`IAST`.

Classe d'AST : ASTalternative

ASTalternative.java

```
public class ASTalternative extends ASTexpression implements IASTalternative {

    private final IASTexpression condition;
    private final IASTexpression consequence;
    private @OrNull final IASTexpression alternant;

    public ASTalternative(IASTexpression condition,
                          IASTexpression consequence,
                          IASTexpression alternant) {
        this.condition = condition;
        this.consequence = consequence;
        this.alternant = alternant;
    }

    @Override public IASTexpression getCondition()   { return condition; }
    @Override public IASTexpression getConsequence() { return consequence; }
    @Override @OrNull public IASTexpression getAlternant()   { return alternant; }
    @Override public boolean isTernary() { return this.alternant != null; }
}
```

Simple classe conteneur pour les attributs d'un nœud alternative.

Note : les méthodes retournent une interface `IASTexpression` !

$\Longrightarrow$ programmer vis à vis d'une interface, pas d'une implantation

Associations : IASTbinding

IASTblock.java

```
public interface IASTblock extends IASTexpression {

    interface IASTbinding extends IAST {
        IASTvariable getVariable();
        IASTexpression getInitialisation();
    }

    IASTbinding[] getBindings();
    IASTexpression getBody();
}
```

Un bloc IASTblock contient un nombre arbitraire de variables locales i.e., d'associations variable / expression.

$\Longrightarrow$ l'interface locale IASTblock.ASTbinding dénote une telle association.

Associations : ASTbinding

ASTblock.java

```
public class ASTblock extends ASTexpression implements IASTblock {

    public static class ASTbinding extends AST implements IASTbinding {
        public ASTbinding (IASTvariable variable, IASTexpression initialisation) {
            this.variable = variable;
            this.initialisation = initialisation;
        }
        private final IASTvariable variable;
        private final IASTexpression initialisation;

        @Override public IASTvariable getVariable() { return variable; }
        @Override public IASTexpression getInitialisation() { return initialisation; }
    }

    public ASTblock(IASTbinding[] binding, IASTexpression body) {
        this.binding = binding;
        this.body = body;
    }
    private final IASTbinding[] binding;
    private final IASTexpression body;

    @Override public IASTbinding[] getBindings() { return binding; }
    @Override public IASTexpression getBody() { return body; }
}
```

`ASTblock.ASTbinding` est une classe locale conteneur pour une association.

Programmes : (I)ASTprogram

IASTprogram.java

```
public interface IASTprogram extends IAST {
    IASTexpression getBody();
}
```

ASTprogram.java

```
public class ASTprogram extends AST implements IASTprogram {

    public ASTprogram(IASTexpression expression)
    { this.expression = expression; }

    protected IASTexpression expression;

    @Override public IASTexpression getBody()
    { return this.expression; }
}
```

Pour l'instant : un simple conteneur pour une expression.

Fabrique d'AST 1/2

IASTfactory.java

```
public interface IASTfactory {

    IASTexpression newIntegerConstant(String value);
    IASTexpression newFloatConstant(String value);
    IASTexpression newStringConstant(String value);
    IASTexpression newBooleanConstant(String value);
    IASTexpression newSequence(IASTexpression[] asts);
    IASTexpression newInvocation(IASTexpression function, IASTexpression[] arguments);
    IASTexpression newBlock(IASTbinding[] binding, IASTexpression body);
    IASTexpression newUnaryOperation(IASToperator operator, IASTexpression operand);
    IASTexpression newBinaryOperation(
        IASToperator operator, IASTexpression leftOperand, IASTexpression rightOperand);
    IASTexpression newAlternative(
        IASTexpression condition, IASTexpression consequence, IASTexpression alternant);

    IASTprogram  newProgram(IASTexpression expression);
    IASToperator newOperator(String name);
    IASTvariable newVariable(String name);
    IASTbinding  newBinding(IASTvariable v, IASTexpression exp);
}
```

Design pattern factory method :

- une interface `IASTfactory` indique comment créer tous les types d'AST

Fabrique d'AST 2/2

ASTfactory.java

```
public class ASTfactory implements IASTfactory {
    @Override public IASTprogram newProgram(IASTexpression expression)
    { return new ASTprogram(expression); }

    @Override public IASToperator newOperator(String name)
    { return new ASToperator(name); }

    @Override public IASTsequence newSequence(IASTexpression[] asts) {
    { return new ASTsequence(asts); }
    ...
}
```

Design pattern factory method :

- une classe concrète `ASTfactory` implante l'interface par `new`
- un client d'AST est paramétré par une instance d'`IASTfactory`
  - il n'appelle pas `new` directement
  - il ne référence aucune classe concrète, seulement des interfaces

$\Longrightarrow$ encapsulation de la création d'AST, indépendance et extensibilité

(cf. transparent suivant)

Construction de l'AST via le *Listener* ANTLR

ILPMLListener.java

```
package com.paracamplus.ilp1.parser.ilpml;

public class ILPMLListener implements ILPMLgrammar1Listener {

    protected IASTfactory factory;

    public ILPMLListener(IASTfactory factory) {
        super();
        this.factory = factory;
    }

    @Override public void exitVariable(VariableContext ctx) { ... }
    @Override public void enterVariable(VariableContext ctx) { }
    ...
}
```

- implantation de l'interface `ILPMLgrammar1Listener` générée par ANTLR
- classe paramétrée par une fabrique `IASTfactory`
- une méthode `enterXXX` et `exitXXX` par règle de grammaire `XXX`
- les méthodes `enterXXX` sont vides
- les méthodes `exitXXX` font tout le travail (transparents suivants)

Construction de l'AST, exemple 1/3

Exemple : opération binaire dans une expression.

ILPMLgrammar1.g4

```
expr returns [com.paracamplus.ilp1.interfaces.IASTexpression node]
    ...
    | arg1=expr op=('*' | '/' | '%') arg2=expr # Binary
```

ILPMLListener.java

```
@Override
public void exitBinary(BinaryContext ctx) {
  ctx.node = factory.newBinaryOperation(
      factory.newOperator(ctx.op.getText()),
      ctx.arg1.node,
      ctx.arg2.node);
}
```

- récupère le texte de l'opération : `ctx.op.getText()`
- récupère l'AST des sous-expressions : `ctx.arg1.node` et `ctx.arg2.node`
- construit le nouveau nœud AST : `factory.newBinaryOperation(...)`
- stocke le résultat dans le nœud de grammaire courant `ctx.node`
  $\Longrightarrow$ il sera disponible lors de l'application des règles englobantes

Construction de l'AST, exemple 2/3

Exemple : alternative.

ILPMLgrammar1.g4

```
| 'if' condition=expr 'then' consequence=expr
  ('else' alternant=expr)? # Alternative
```

ILPMLListener.java

```
@Override
public void exitAlternative(AlternativeContext ctx) {
    ctx.node = factory.newAlternative(
        ctx.condition.node,
        ctx.consequence.node,
        (ctx.alternant == null ? null : ctx.alternant.node));
}
```

- penser au cas où la branche `else` optionnelle est absente
  `ctx.alternant == null`

Construction de l'AST, exemple 3/3

Exemple : séquence d'instructions.

ILPMLgrammar1.g4

```
: '(' exprs+=expr (';'? exprs+=expr)* ';'? ')' # Sequence
```

ILPMLListener.java

```
protected IASTexpression[] toExpressions(List<ExprContext> ctxs) {
    if (ctxs == null) return new IASTexpression[0];
    IASTexpression[] r = new IASTexpression[ctxs.size()];
    int pos = 0;
    for (ExprContext e : ctxs) r[pos++] = e.node;
    return r;
}

@Override
public void exitSequence(SequenceContext ctx) {
    ctx.node = factory.newSequence(toExpressions(ctx.exprs));
}
```

- ANTLR se charge d'accumuler toutes les expressions dans une liste de contextes `ctxs`, grâce à `exprs+=expr`
- l'utilitaire `toExpressions` convertit la liste en tableau et extrait le nœud de chaque contexte

Pilote d'analyse syntaxique générique

Parser.java

```
public class Parser {

    protected ILPMLParser ilpmlparser;
    public void setILPMLParser(ILPMLParser parser) { this.ilpmlparser = parser; }

    public IASTprogram parse(File file) throws ParseException {
        Input input = new InputFromFile(file);
        ...
        if (file.getName().endsWith(".ilpml")) {
            if (ilpmlparser == null)
                throw new ParseException("ILPML parser not set");
            ilpmlparser.setInput(input);
            IASTprogram program = ilpmlparser.getProgram();
            return program;
        }
        throw new ParseException("file extension not recognized");
    }
}
```

ILP supporte en réalité plusieurs analyseurs syntaxiques : ILPML et XML !

`Parser` choisit le bon analyseur en fonction de l'extension (`.ilpml` ou `.xml`).

`Parser` est paramétré par l'analyseur ILPML (celui-ci changera pour ILP2, etc.)

Pilote d'analyse syntaxique ILPML

ILPMLParser.java

```
protected IASTfactory factory;
public ILPMLParser(IASTfactory factory) { this.factory = factory; }

protected Input input;
public void setInput(Input input) { this.input = input; }

public IASTprogram getProgram() throws ParseException {
  try {
    ANTLRInputStream in = new ANTLRInputStream(input.getText());
    // flux de caractères -> analyseur lexical
    ILPMLgrammar1Lexer lexer = new ILPMLgrammar1Lexer(in);
    // analyseur lexical -> flux de tokens
    CommonTokenStream tokens = new CommonTokenStream(lexer);
    // flux de tokens -> analyseur syntaxique
    ILPMLgrammar1Parser parser = new ILPMLgrammar1Parser(tokens);
    // démarage de l'analyse syntaxique
    ILPMLgrammar1Parser.ProgContext tree = parser.prog();
    // parcours de l'arbre syntaxique et appel du Listener
    ParseTreeWalker walker = new ParseTreeWalker();
    ILPMLListener extractor = new ILPMLListener(factory);
    walker.walk(extractor, tree);
    return tree.node;
  } catch (Exception e) { throw new ParseException(e);}
}
```

Appelle les services ANTLR dans le bon ordre, en passant notre *Listener*.

`setInput` spécifie la source de l'entrée texte (chaîne, fichier, etc.).

Principes pour l'extension de la syntaxe

L'extension du langage commence par l'extension de la syntaxe d'entrée :

- si des nouveaux nœuds AST sont nécessaires :
  - ajouter les interfaces `IAST` et les classes `AST`
  - enrichir la fabrique `IASTfactory` / `ASTfactory` (par héritage)
- écrire un nouveau fichier de grammaire ANTLR `.g4`
- écrire un nouveau *Listener*
  obéissant à l'interface produite par ANTLR pour la nouvelle grammaire
  copier-coller depuis `ILPMLgrammar1.g4` et `ILPMLListener.java` si nécessaire ;
  l'héritage de ces fichiers est difficile à cause de limitations d'ANTLR !
- hériter d'`ILPMLParser` en spécifiant notre nouveau *Listener*
  et notre nouvelle fabrique
- écrire des exemples de tests utilisant la nouvelle syntaxe
  et vérifier que le comportement des anciens programmes n'a pas changé !

Toujours travailler dans un nouveau *package* Java.
Ne jamais modifier les fichiers existants ;
l'ancienne grammaire doit rester accessible !

cf. détails dans le TME 1.

Syntaxe XML : exemple (bonus)

exemple .ilpml

```
if true then print("invisible");
48
```

exemple .xml correspondant

```
<program>
  <sequence>
    <alternative>
      <condition>
        <boolean value='true'/>
      </condition>
      <consequence>
        <invocation>
          <function>
            <variable name='print'/>
          </function>
          <arguments>
            <string>invisible</string>
          </arguments>
        </invocation>
      </consequence>
    </alternative>
    <integer value='48'/>
  </sequence>
</program>
```

À regarder chez soi : l'analyseur syntaxique XML et les exemples `.xml` dans `SamplesILP1/`

Tests

Principe

But du test :

- vérifier qu'un programme vérifie sa spécification
  e.g. : pas d'exception au *top-level*, retourne bien le résultat attendu
- vérifier l'absence de régression (évolution du programme)

L'exécution d'un programme ILP a deux résultats :

- la valeur de retour
  (un programme est une expression, et toute expression ILP a une valeur)
- le texte affiché sur la sortie standard par `print` et `newline`

Principe du test ILP :

On se donne un ensemble de triplets de fichiers :

- `test.ilpml` : programme source ILP
- `test.result` : valeur de retour attendue
- `test.print` : sortie texte attendue

cf. le répertoire `SamplesILP1`

puis, on lance le compilateur ou l'interprète sur chaque `test.ilpml`
pour vérifier que les sorties sont identiques à `test.result` et `test.print`.

JUnit 4

JUnit 4 : *framework* de test unitaire
utilisant les annotations Java.

Une classe de test doit :

- contenir un constructeur sans argument
- contenir une ou plusieurs méthodes de test :
  - annotées avec `@Test`
  - `public` et sans argument (donc bien différente d'une méthode `main`)
- utiliser des assertions de la bibliothèque JUnit 4
  `assertTrue`, `assertFalse`, `assertEqual`, etc.
- éventuellement des méthode `@Before` et `@After`

Il est également possible de lancer un test sur une famille de données :

- une méthode `static @Parameters` fournit une liste de paramètres
- un constructeur avec argument est alors utilisé

JUnit 4 : principe d'exécution

Le lancement du test peut se faire avec "*Run As*" puis "*JUnit Test*" sous Eclipse.

Pour chaque méthode `@Test`
et éventuellement chaque valeur de paramètre,
JUnit va :

- instancier la classe
- appeler les méthode `@Before`
- appeler la méthode de test

  l'exécution du test s'arrête au premier échec d'assertion
- appeler les méthodes `@After`

Eclipse affiche le nombre de tests sans aucune erreur.

Test d'ILP : exemple de l'interprète

InterpreterTest.java (extrait)

```
@RunWith(Parameterized.class) public class InterpreterTest {
    @Parameters(name = "0") public static Collection<File[]> data() throws Exception
    { return InterpreterRunner.getFileList(samplesDirName, pattern); }

    public InterpreterTest(final File file) { this.file = file; }
    protected File file;

    @Test public void processFile() throws ... {
        InterpreterRunner run = new InterpreterRunner();
        configureRunner(run);
        run.testFile(file);
        run.checkPrintingAndResult(file);
    }

    public void configureRunner(InterpreterRunner run) throws EvaluationException {
        IASTfactory factory = new ASTfactory();
        run.setILPMLParser(new ILPMLParser(factory));
        ...
    }
}
```

La classe utilitaire `InterpreterRunner` automatise :

- l'extraction de la liste de fichiers sources (`getFileList`)
- l'appel à l'analyseur syntaxique et l'interprète (`testFile`)
- la comparaison entre le résultat attendu et obtenu (`checkPrintingAndResult`)

Résumé

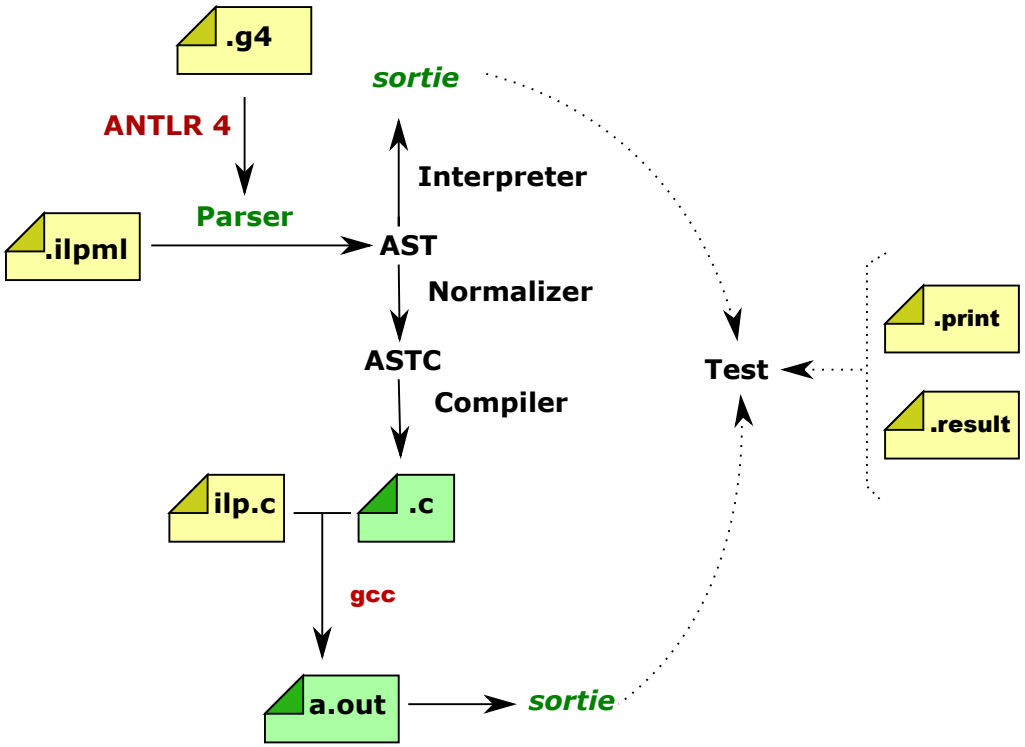

Nous avons vu :

- syntaxe concrète d'ILP1
- encodage en grammaire ANTLR 4
- actions de grammaire par *Listener*
- représentation de programmes avec l'arbre syntaxique abstrait
- choix sémantiques d'ILP1
- test automatisé JUnit 4

Prochain cours :
l'interprète ILP1 en Java.