Master STL, Université Pierre et Marie Curie

Année 2020-2021

TME 7 – Coroutines

Antoine Miné

1 Présentation

Les coroutines sont une forme étendue d'appels de fonctions, permettant un flot de contrôle plus complexe. Lors d'un appel de fonction classique, l'exécution de l'appelant est suspendue jusqu'à la terminaison complète de la fonction appelée. Un appel de coroutine permet, au contraire, à la coroutine appelée de s'interrompre temporairement, avant sa fin normale, et de revenir à l'appelant. L'appelant pourra alors continuer l'exécution de son code un moment, puis revenir à la coroutine pour reprendre son exécution à l'endroit où celle-ci s'était interrompue, jusqu'à sa prochaine suspension, et ainsi de suite. Voici un exemple de coroutine :

```
function f()
                                                            let x = costart f() in (
                                                             print("a1 ");
     print("b1 ");
                                                            resume(x);
     yield();
                                                             print("a2 ");
     print("b2 ");
                                                             resume(x);
                                                             print("a3 ");
     yield();
     print("b3 ")
                                                            resume(x);
                                                            print("a4 ");
                                                            resume(x);
                                                            print("a5 ")
10
                                                         21
                                                            )
```

Le résultat affiché sera : a1 b1 a2 b2 a3 b3 a4 a5.

Nous notons les points suivants :

- Une coroutine **f** est définie comme une fonction globale.
- L'appel à f() est remplacé par let x = costart f(), qui démarre une nouvelle instance de la coroutine f et stocke l'instance dans x, sans commencer l'exécution de f.
- f commence réellement à s'exécuter au premier resume(x), donc après l'affichage de a1.
- L'exécution se poursuit dans f, jusqu'au premier yield(). Elle affiche donc b1.
- Après un yield(), le flot d'exécution reprend dans la fonction appelante, immédiatement après l'instruction resume(x). L'exécution affiche donc a2.
- L'exécution se poursuit dans l'appelant jusqu'au deuxième resume(x). À ce moment, f reprend la main au deuxième yield().
- L'exécution continue de sauter de l'appelant à f, au gré des yield() et des resume(x).
- Après la fin de f atteinte, les instructions resume(x) n'ont plus aucun effet, donc l'affichage de a4 est immédiatement suivi de a5.

L'exemple suivant illustre deux points supplémentaires : le passage d'arguments à une coroutine et l'exécution concurrente de plusieurs instances de la même coroutine (chacune ayant ses propres variables locales et son flot d'instructions) :

La notion de coroutine existe en Python, à travers les générateurs. Par contre, de nombreux langages populaires (C, Java, C++) n'incluent pas nativement les coroutines.

Objectif. Ajouter à ILP3 le support pour les coroutines.

Buts:

- revoir l'ajout d'une construction dans ILP, de la syntaxe à l'interprète et au compilateur ;
- comprendre l'appel dans ILP aux fonctions globales;
- comprendre les limitations inhérentes au modèle d'exécution à pile unique, et comment y remédier;
- revoir ou s'initier aux *Threads* Java.

Version d'ILP. Nous nous baserons sur le code ILP3. Ce code est disponible sur le GitLab du cours (https://stl.algo-prog.info), dans le projet ILP3 du groupe du semestre en cours (DLP-2020oct pour 2020-2021). Comme pour ILP1 et ILP2, vous devrez commencer par en faire un *fork* personnel, puis par importer ce nouveau projet dans Eclipse. Vous ajouterez le code de ce TME dans votre *fork* d'ILP3 (vous n'avez pas besoin d'intégrer les TME précédents dans ILP3).

Nous travaillerons dans le package com.paracamplus.ilp3.ilp3tme7.

2 Travail à réaliser

2.1 Grammaire et AST

L'ajout des coroutines nécessitera l'ajout d'une construction dans la grammaire du langage permettant de créer une instance d'une coroutine. La syntaxe de cette construction est similaire à celle d'un appel de fonction, préfixé du nom-clé costart; ainsi, le fragment de programme suivant est une expression valide :

```
costart f(x,y)
```

Les instructions yield et resume seront par contre représentées par des primitives (comme print), ce qui évite des modifications supplémentaires de la grammaire et de l'AST.

Travail à réaliser : écrivez une grammaire ANTLR ILPMLgrammar3tme7 qui étend la grammaire d'ILP3 avec la construction costart; étendez également l'AST avec un nœud ASTcostart, inspiré de ASTinvocation.

2.2 Interprétation

2.2.1 Threads

La notion de coroutine n'existant pas en Java, nous allons l'implanter à l'aide de threads. Rappelons que les threads sont des processus légers qui permettent en Java de créer plusieurs unités d'exécution indépendantes, partageant les même objets.

Les instances de coroutines seront donc représentées par une classe CoroutineInstance que vous devrez créer, dérivant de java.lang.Thread.

2.2.2 Démarrage

L'interprétation de l'instruction costart f(x,y) sera de créer un nouvel objet de classe CoroutineInstance, de lancer l'exécution de la thread correspondante (par la méthode start héritée de Thread) et de renvoyer cet objet pour qu'il soit stocké dans une variable du programme. Rappelons qu'un appel à start sur une instance de classe dérivant de Thread créera une nouvelle unité d'exécution qui exécutera la méthode run de cette classe sans interrompre l'appelant.

Travail à réaliser: programmez une classe CoroutineInstance dérivant de Thread et dont la méthode run() lancera l'interprétation de la fonction f(x,y), passée en argument de costart.

2.2.3 Flot de contrôle avec des sémaphores

Par défaut, les threads sont exécutées en concurrence, indépendemment les unes des autres. Cependant, les coroutines obéissent à des règles strictes de flot de contrôle : un resume met en attente la thread de l'appelant et autorise l'exécution de la thread coroutine ; un yield met en attente la thread coroutine et autorise l'exécution de la thread ayant appelé resume. Nous devons donc ajouter un mécanisme d'attente entre threads.

Nous suggérons pour cela l'emploi d'objets java.util.concurrent.Semaphore. Si un sémaphore est créé avec une valeur initiale nulle, alors un premier appel à aquire permettra à une thread de se mettre en attente, jusqu'à ce qu'une autre thread la délivre avec la méthode release sur le même sémaphore. Une coroutine aura besoin de deux sémaphores, le premier pour mettre en attente une coroutine jusqu'au prochain resume, et le deuxième pour mettre en attente la thread ayant appelé resume jusqu'au prochain yield.

Travail à réaliser: implantez dans CoroutineInstance des méthodes yieldCoroutine() et resumeCoroutine() modélisant le passage de contrôle de la coroutine à l'appelant, et de l'appelant à la coroutine; modifiez run pour qu'elle attende le premier resumeCoroutine avant d'appeler la fonction coroutine. Prenez garde au cas où un resumeCoroutine est appelé sur une coroutine ayant terminé son exécution.

2.2.4 Liaison avec l'interpréteur

Il reste à connecter l'interpréteur à la classe CoroutineInstance. Lors d'un appel à resume, l'instance de coroutine à réveiller est passée en argument (il faudra tout de même vérifier le type de l'objet). Lors d'un appel à yield, l'instance de coroutine qui s'interrompt n'est pas passée en argument : c'est implicitement l'instance en cours d'exécution. Pour retrouver la coroutine courante, la méthode statique Thread.currentThread pourra être utile...

Travail à réaliser : implantez des classes Yield et Resume pour les primitives correspondantes; enrichissez les classes Interpreter et GlobalVariableStuff pour gérer l'instruction costart et les nouvelles primitives.

Comme toujours, vous testerez votre implantation en développant une banque de programmes de test ayant des corroutines, et vous ajouterez vos tests dans l'intégration continue du serveur GitLab du cours (fichier .gitlab-ci.yml).

2.3 Compilation

2.3.1 Contextes

Une implantation des coroutines en C est possible via les fonctions getcontext, setcontext, makecontext et swapcontext de la bibliothèque standard POSIX, disponible en particulier sous Linux et MacOS X (ucontext.h). Ces fonctions manipulent le contexte d'exécution, qui correspond non seulement à la position dans le programme mais aussi à la pile complète. Elles généralisent donc les fonctions setjmp et longjmp vues en cours. Ces dernières permettent uniquement de « sauter » à un point antérieur de la pile (i.e., un appelant), tandis que les fonctions de contexte permettent de « sauter » entre plusieurs piles, simulant ainsi plusieurs unités d'exécution indépendantes avec leur pile d'appel, leurs variables locales, etc.

La création d'un nouveau contexte nécessite plusieurs étapes :

- allouer un objet c de type ucontext_t;
- initialiser c avec getcontext;
- allouer un bloc mémoire pour la pile du contexte, et renseigner les champs uc_stack.ss_sp et us_stack.ss_size;
- définir la fonction exécutée quand le contexte est actif, avec makecontext.

Une fois le contexte créé, on peut le rendre actif avec setcontext. La fonction swapcontext sera plus utile : elle permet en un seul appel de sauter au contexte donné et de stocker le contexte courant, ce qui permet de revenir plus tard au point d'appel swapcontext par un autre swapcontext ou un setcontext.

2.3.2 Bibliothèque d'exécution

Il est nécessaire d'enrichir la bibliothèque d'exécution C avec la notion d'instance de coroutine et les fonctions pour y accéder.

Travail à réaliser :

- Enrichir le type ILP_Object dans ilp.h avec un champ coroutine. Celui-ci contiendra, entres autres, des contextes permettant de savoir où sauter après un yield ou un resume.
- Ajouter à ilp.c des primitives ILP_yield(), ILP_resume(coroutine).
- Ajouter à ilp.c une primitive ILP_costart(f, argc, ...) en s'inspirant de ILP_invoke. La primitive crée un nouveau contexte appelant la fonction f avec les arguments spécifiés et renvoie un nouvel ILP_Object correspondant à l'instance de coroutine créée.

Attention à ce qui ce passe quand la fonction coroutine se termine. Le comportement par défaut de swapcontext est de terminer le programme, ce qui n'est pas souhaitable, mais le champ uc_link du contexte permet de changer ce comportement...

2.3.3 Normalisation

Le compilateur effectue une spécialisation de certains nœuds de l'AST; en particulier, il classifie les d'appels ASTinvocation en plusieurs types, selon leur complexité: ASTCcomputedInvocation, ASTCglobalInvocation, etc. Nous supposons ici que l'instruction costart est toujours utilisée avec, comme argument, une fonction globale. L'étape de normalisation va naturellement transformer nos ASTcostart en nouveaux nœuds ASTCglobalCostart, inspirés de ASTCglobalInvocation. Nous ignorerons les autres types d'invocation.

Travail à réaliser : ajouter la classe ASTCglobalCostart et adapter la classe Normalizer pour traiter ASTcostart.

2.3.4 Compilation

Finaliser l'adaptation du compilateur est maintenant assez simple.

Travail à réaliser :

- Ajouter la gestion des primitives yield et resume à GlobalVariableStuff (elles se traduisent respectivement en ILP_yield et ILP_resume).
- Ajouter la gestion du nœud ASTCglobalCostart à la classe Compiler. Il est possible de s'inspirer de la gestion de IASTCglobalInvocation de Compiler, sauf que l'appel à ILP_invoke est remplacé par un appel à ILP_costart.

2.4 Rendu

Vous effectuerez un rendu en vous assurant que tout le code développé a été envoyé sur le serveur $GitLab\ (push)$ dans votre fork d'ILP3. Vous vous assurerez que les tests d'intégration continue développés ont bien été configurés et fonctionnent sur le serveur. Vous ajouterez un tag « rendu-initial-tme7 » en fin de séance, puis un tag « rendu-final-tme7 » quand le TME est finalisé.